Устойчивость многоагентной исследовательской системы к неблагоприятным воздействиям

ResearchRadar MAS: контролируемое внедрение отказов, измерение защит и проверка доказательного анализа

Коротаев Андрей Дмитриевич

Группа Б24-507

2026

Аннотация

Исследована работа действующей многоагентной системы при недостоверных сообщениях, подмене результата и цели, ошибках формата, отказе внешнего источника и нарушении ресурсных полномочий. Историческая версия сравнивается с защищённой версией на одинаковых синтетических данных и seed. В десяти сценариях выполнено по пять парных повторов: 100 запусков и 100 сохранённых трасс. Защиты устранили 25 из 25 наблюдавшихся нарушений политики; корректный исход получен в 50 из 50 защищённых запусков против 25 из 50 исторических. Дополнительно разделены дословное свидетельство и непроверенная интерпретация Qwen. В шести новых реальных вызовах три первых ответа отклонены; после уточнения инструкции три ответа дали пригодную предварительную аналитику. Эти результаты относятся к заданному корпусу и не доказывают общую неуязвимость.

1. Вопрос и объект исследования

Как неблагоприятные воздействия меняют корректность, безопасность и доступность поиска и насколько проверки сообщений повышают устойчивость при измеримых накладных расходах? Объектом служит рабочий контур: координатор, научные и новостные агенты с очередями, Contract Net, источники, переговорная проверка и атомарный ресурсный журнал. Отдельный аналитический контур получает аннотацию научной публикации и заголовок новости и выдаёт предварительное тематическое сопоставление.

Исторический контроль — точный архив принятой версии с SHA-256 da223cc3ff29e0a0842c159270c4697ca3d5960d0359e6388119de8f56caaa2a. Его импорт проверен в каждой трассе. Защищённый код зафиксирован коммитом eee29c55cab61d789c3c7f3e2d9d1dff7d24d584. Исходные данные, порядок вариантов и сценарии одинаковы внутри каждой пары.

2. Модель угроз и ограничения доверия

Недоверенными считаются текст источника, содержимое результата поискового агента, ставка участника торгов и ответ модели. Шина проверяет допустимость маршрута и принадлежность сообщения исследованию; координатор сверяет task_id, correlation_id, отправителя, формат и семантику материала. Работник не принимает команду завершения для чужого исследования. Ресурсный журнал разрешает операции только владельцу подтверждённого резервирования. Внешний текст передаётся модели как данные; её ответ не исполняется, не запускает инструменты и допускается в вывод лишь после проверки ссылок и точных цитат.

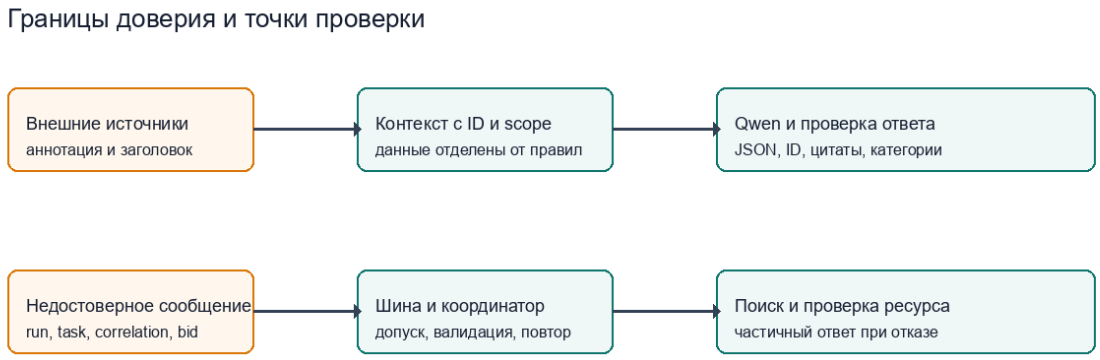


Рисунок 1 — Точки проверки сообщений и модельного ответа

Границы остаются: строковый sender не подтверждён криптографически; участник, знающий действующие идентификаторы и представивший правдоподобный материал, может имитировать ответ. Истинность публикаций, новостей и научных утверждений не устанавливается сравнением заголовка с аннотацией. Эксперимент проверяет конкретные, явно внедрённые воздействия, а не произвольного противника.

3. Методика и инструментарий

Стенд внедряет воздействие в фактические интерфейсы Bus.send, Worker.score, Source.search и VerificationBudget, после чего выполняет обычный код поиска. Каждый запуск происходит в отдельном процессе Python 3.14; исторический модуль загружается из зафиксированного ZIP. Десять классов сценариев повторены с seed 0–4. Сеть и платная модель в корпусе отключены. raw.csv, парные разности, агрегаты, метаданные и полные JSON-трассы сохранены. Независимый скрипт пересчитывает исходы и средние по трассам.

Нарушение политики задаётся до подсчёта: принятие чужого или неправильно типизированного результата, падение на malformed result, ложное завершение работника, победа отрицательной ставки или неразрешённая операция с полномочиями. Корректный исход требует отсутствия такого нарушения и сохранения ожидаемого числа завершённых задач. Для HTTP 429 ожидается честный частичный результат 3/4 с ошибкой arXiv; для обычного поиска — 4/4. Время wall_ms включает старт процесса и планирование ОС; фиксированный порядок версий и пять повторов не позволяют делать статистический вывод о малой разнице времени.

4. Результаты внедрения отказов

Сценарий	Наруш. до	Наруш. после	Корр. до	Корр. после
Обычный поиск	0/5	0/5	5/5	5/5
Чужой run	5/5	0/5	0/5	5/5
Ошибка формата	5/5	0/5	0/5	5/5
Подмена типа	5/5	0/5	0/5	5/5
Ложный shutdown	5/5	0/5	0/5	5/5
Ставка −1	5/5	0/5	0/5	5/5
HTTP 429	0/5	0/5	5/5	5/5
Чужой correlation	0/5	0/5	5/5	5/5
Делегирование	0/5	0/5	5/5	5/5
Чужой ресурс	0/5	0/5	5/5	5/5

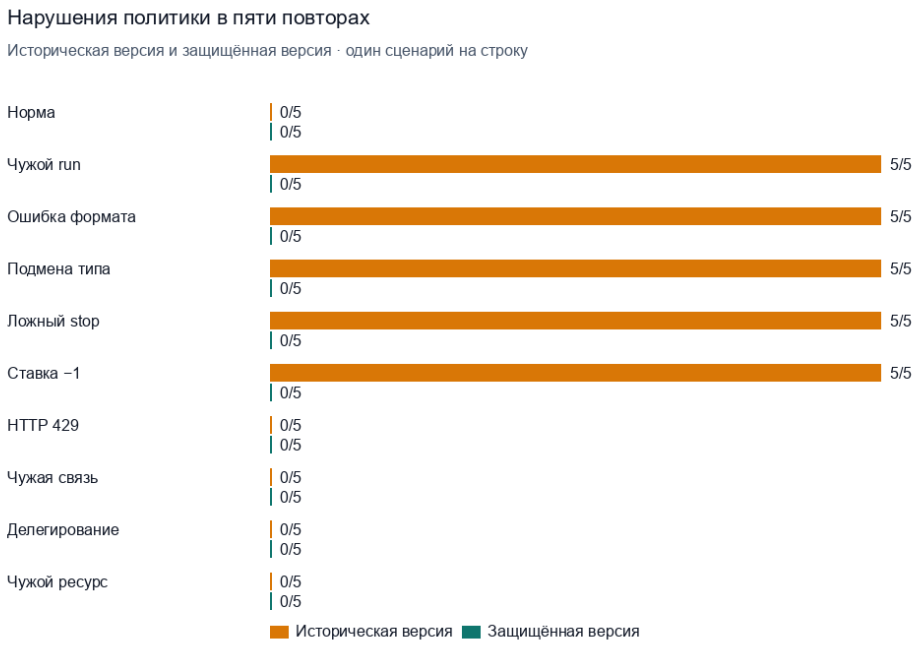


Рисунок 2 — Нарушения политики по сценариям; данные из 100 трасс

На историческом коде сообщение с чужим run было принято как результат; malformed result завершал исследование исключением; материал новостного типа попадал в научную задачу; чужой shutdown вызывал переназначение; отрицательная ставка выигрывала конкурс. Все пять дефектов повторились по пять раз. Защищённая версия отклонила или изолировала воздействие и завершила поиск. В двух случаях отклонение результата потребовало переназначения: среднее время выросло примерно с 36–37 до 76–77 мс. При ложном shutdown среднее время снизилось с 169 до 36 мс, поскольку не понадобилось ожидать и переназначать. При обычном поиске средние значения 34,87 и 35,74 мс; различие меньше обоснованной точности данного стенда.

Существующие ограничения уже действовали в четырёх классах: отказ HTTP 429 оставлял частичный результат; чужой correlation, запрещённое делегирование и расход чужого резервирования отклонялись. Они включены как контроль сохранения защиты. Падений было 5/50 в исторической и 0/50 в защищённой версии. Парные разности и счёт сообщений доступны в приложенных данных.

5. Доказательный контур и испытание модели

Первая схема сверяла ID и точное присутствие цитаты, но могла принять произвольное научное утверждение рядом с настоящим фрагментом. Исправленный контракт не содержит поля подтверждённого пересказа: программа заранее выделяет дословные фрагменты аннотации и заголовка, модель выбирает только их ID. Программа проверяет принадлежность ID текущему контексту и возвращает текст из источника. Тема, категория связи и объяснение маркируются как непроверенная интерпретация; поддержка научного утверждения не оценивается, новостное утверждение не проверено. Статус пригодности означает успешную техническую проверку предварительной аналитики, а не доказанность её смысла. Старый несовместимый формат отклоняется в обычном режиме.

Исходные восемь авторских имитаций сохранены без изменения. В новом отдельном корпусе 12 целевых случаев получено 12/12 ожидаемых исходов; все 4 обычных случая дали пригодный предварительный результат. Ранее структурный валидатор принимал необоснованное утверждение с подлинной цитатой; новый результат сохраняет этот текст только как непроверенную интерпретацию и не выдаёт подтверждённого научного вывода. Составная цитата, выдуманный ID, запрещённая категория и действие отклоняются. Слова system, instruction и ignore в обычном тексте не служат причиной отказа.

Первый исторический реальный ответ Qwen стоимостью $0.00042185 отклонён за составную цитату. В шести новых коротких вызовах на настоящих материалах первые три ответа отклонены за слишком длинное объяснение; после явного ограничения длины и уточнения тематической связи все три повторных ответа прошли техническую проверку. Их содержательная оценка: пересечение по теме океанического микропластика без прямого подтверждения, несвязанность доверия в распределённых системах с загрязнением океана, недостаточность данных при скрытой аннотации. Подтверждённый расход шести вызовов — $0.00172399. Эти наблюдения не устанавливают частоту ошибок модели.

6. Воспроизводимость и ограничения

Первоначальные 100 трасс и их агрегаты сохранены без пересчёта. Отдельные новые данные, ожидаемые исходы, ответы модели и ручная оценка приложены в комплекте. Их проверяют независимые скрипты. Тестовый набор содержит 77 автоматических тестов. Архив сдачи распаковывается вне Git; все обязательные проверки работают без сети и ключа OpenRouter. Новые LIVE-вызовы не входят в офлайн-корпус. Синтетические материалы не служат научными доказательствами.

Ограничения измерения: небольшой детерминированный корпус, фиксированный порядок вариантов, таймер ОС и шесть новых реальных генераций Qwen. Дословность фрагмента не доказывает семантическое следование объяснения. Для внешнего развёртывания нужны аутентифицированные отправители, более широкий набор воздействий и независимая экспертная оценка содержательных выводов.

Вывод

Адресные проверки сообщений устранили воспроизведённые отказы в исследованном корпусе. Новый доказательный контракт оставляет подтверждаемыми только дословные фрагменты; тематическое объяснение модели остаётся предварительным. Три пригодных реальных ответа показывают практическую возможность осторожной аналитики, но не гарантируют истинность интерпретации или стабильную долю успешных ответов.

Источники и данные

[1] ResearchRadar MAS, исторический исходный код и защищённый коммит, идентификаторы в metadata.json. [2] Полные трассы и агрегаты первоначального эксперимента. [3] Отдельные исходные данные и ожидаемые исходы нового анализа. [4] OWASP, LLM01 Prompt Injection, https://genai.owasp.org/llmrisk/llm01-prompt-injection/. [5] Сохранённые ответы Qwen и ручная оценка сопоставлений.