НИЯУ МИФИ

Теория многоагентных систем

Устойчивость многоагентной исследовательской системы к неблагоприятным воздействиям

ResearchRadar MAS: диверсионные испытания,
измерение защит и проверка доказательного анализа

Выполнил: Коротаев Андрей Дмитриевич
Группа: Б24-507

Москва — 2026

Аннотация

Исследована устойчивость действующей многоагентной системы ResearchRadar MAS к нарушениям формата и маршрутизации сообщений, подмене результата и управляющей команды, ошибочной ставке в Contract Net, отказу внешнего источника и нарушениям ресурсных полномочий. Для десяти сценариев выполнено по пять парных запусков исторической и защищённой версий (100 трасс). В первоначальной версии зарегистрировано 25 нарушений политики на 50 запусков; в защищённой версии — 0. Корректных исходов стало 50 из 50 вместо 25 из 50. Отдельно проверен контракт доказательного анализа Qwen: подлинная цитата не должна автоматически подтверждать сформулированный моделью научный вывод. Все результаты ограничены применёнными тестовыми данными и настройками стенда.

1. Цель и объект исследования

Цель исследования — установить, какие неблагоприятные воздействия вызывают отказ или нарушение правил взаимодействия агентов, реализовать адресные защитные проверки и оценить изменения в корректности выполнения задач и накладных расходах.

ResearchRadar MAS объединяет координатор, научных и новостных исполнителей, очередь заданий, протокол контрактной сети (Contract Net), интерфейсы внешних источников и механизм переговорной проверки с учётом ресурса. Система собирает научные публикации и сообщения по исследовательскому вопросу, распределяет задачи между агентами и сохраняет результаты. Отдельный аналитический контур использует Qwen для предварительного тематического сопоставления научной аннотации и новостного заголовка.

В рамках этой работы анализируется не универсальная защищённость сервиса, а устойчивость заданных интерфейсов к воспроизводимым воздействиям. Набор сценариев, исходные данные и повторные запуски сохранены в архиве сдачи.

2. Модель угроз и реализованные ограничения

Недоверенными считаются внешние тексты, содержимое ответов исполнителей, ставки кандидатов на задачу и выход языковой модели. У каждого сообщения есть контекст исследования и задания. Координатор должен проверять принадлежность ответа соответствующему заданию, допустимость отправителя, корректность типа материала и структуру данных.

Защищённая версия контролирует run_id, task_id и correlation_id, валидирует результаты и ставки, отказывает в операциях вне полномочий владельца резервирования и не допускает завершения чужого исследования. Если результат отклонён, задание может быть переназначено. При недоступности внешнего источника система сохраняет частичный результат с указанием ошибки.

Ответ Qwen рассматривается как данные, а не как исполняемая инструкция. Проверяются формат, категория, идентификатор доказательства и дословное соответствие фрагменту текущего источника; пояснение модели не получает автоматического статуса доказанного научного факта.

Описанные проверки не являются криптографической аутентификацией: строковый идентификатор отправителя сам по себе не подтверждает его личность. Это ограничение явно учитывается в интерпретации результатов.



Рисунок 1 — Границы доверия и точки контроля сообщений и ответов Qwen

3. Методика диверсионных испытаний

Стенд внедряет воздействия в действующие интерфейсы Bus.send, Worker.score, Source.search и VerificationBudget, после чего запускает обычный исследовательский конвейер. Исторический код загружается из зафиксированного архива версии lab3-v1.1; защищённый код соответствует экспериментальному коммиту eee29c55cab61d789c3c7f3e2d9d1dff7d24d584. Для каждой пары используются одинаковые синтетические данные, сценарий и seed.

В эксперимент включены десять сценариев и пять seed (0–4) на каждый вариант. Всего проведено 10 × 5 × 2 = 100 запусков; каждый запуск выполнялся в отдельном процессе Python 3.14.7. Для исходного корпуса сеть и платные вызовы LLM отключены, чтобы исключить нестабильность внешних сервисов и расходы. Сохранены полные трассы, исходные измерения, парные разности и агрегаты.

3.1. Критерии оценки

Нарушение политики фиксируется при принятии результата чужого исследования, некорректного или неправильно типизированного сообщения, ложного завершения, победы отрицательной ставки либо запрещённой операции с ресурсом. Корректный исход означает отсутствие нарушения и получение ожидаемого результата сценария. Для обычного поиска ожидается 4 из 4 заданий; для специально воспроизведённого HTTP 429 — честно обозначенный частичный результат 3 из 4.

Дополнительные показатели — число падений процесса, сообщения координации, повторные назначения и wall-clock время. Время включает запуск процесса и планирование ОС, а последовательность выполнения вариантов фиксирована. Поэтому небольшие различия миллисекунд не интерпретируются как статистически значимый эффект.

4. Результаты: до защиты и после неё

Сценарий	Нарушения до	Нарушения после	Корректно до	Корректно после
Обычный поиск	0/5	0/5	5/5	5/5
Чужой run_id	5/5	0/5	0/5	5/5
Ошибка формата	5/5	0/5	0/5	5/5
Подмена типа	5/5	0/5	0/5	5/5
Ложный shutdown	5/5	0/5	0/5	5/5
Ставка −1	5/5	0/5	0/5	5/5
HTTP 429	0/5	0/5	5/5	5/5
Чужой correlation_id	0/5	0/5	5/5	5/5
Запрещённое делегирование	0/5	0/5	5/5	5/5
Чужой ресурс	0/5	0/5	5/5	5/5

Таблица 1 — Сводные результаты десяти сценариев; источник: experiments/lab4/results/summary.json

Пять классов воздействий вызывали по пять нарушений политики в исторической реализации: чужой run_id, некорректный результат, несоответствие типа материала, поддельный shutdown и отрицательная ставка. Во всех пяти классах защищённая версия восстановила ожидаемое поведение. В остальных сценариях нарушения не возникали уже до доработки: они использованы как контроль сохранения ранее действовавших ограничений.

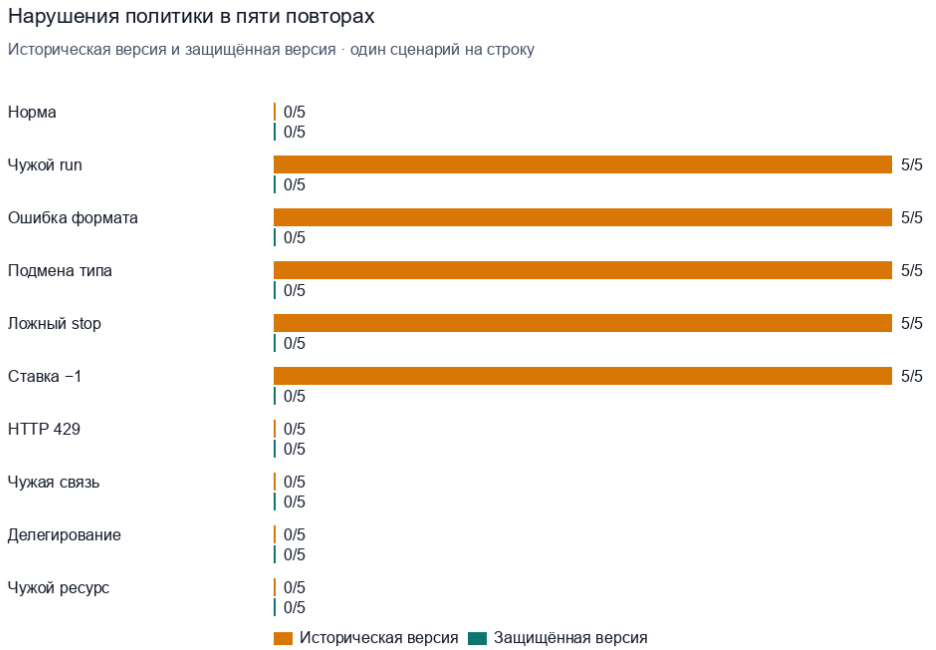


Рисунок 2 — Число нарушений политики в пяти повторах каждого сценария

Итог по всем 50 парам: 25/50 нарушений политики до введения защит и 0/50 после; корректных исходов — 25/50 и 50/50 соответственно. Падений — 5/50 против 0/50. Это свидетельствует об устранении воспроизведённых отказов в пределах выбранного корпуса, но не о защите от всех возможных воздействий.

4.1. Накладные расходы

Повторная проверка результата иногда увеличивает время обработки: при ошибке формата среднее время составляет 36,47 мс до защиты и 76,82 мс после, при подмене типа — 37,32 и 75,85 мс соответственно. Дополнительное время связано с отклонением некорректного ответа и переназначением задания. В сценарии ложного shutdown время уменьшилось со 169,23 до 35,81 мс, поскольку удалось избежать ненужного ожидания и переназначения.

Для обычного поиска среднее время составило 34,87 и 35,74 мс. По пяти повторам с включёнными накладными расходами запуска процесса нельзя надёжно установить значимость такой разницы. Защита оценивается прежде всего по корректности, а не как средство универсального ускорения.

5. Проверка доказательного анализа с Qwen

В исходном варианте валидатор мог принять свободное научное утверждение, если рядом с ним присутствовала настоящая цитата. Сам факт наличия цитаты, однако, не доказывает, что вывод семантически следует из неё. Поэтому модель вывода изменена: программа предоставляет набор дословных фрагментов научной аннотации и новостного заголовка, а Qwen выбирает только доступные идентификаторы evidence_id. Проверяемые цитаты восстанавливаются программой из исходного контекста.

Поля темы, типа связи и объяснения сохраняются как предварительная, непроверенная интерпретация. Для них не утверждается научная доказанность. Составная цитата, вымышленный evidence_id, запрещённая категория и предложенное действие отклоняются. Употребление слов system, instruction и ignore в обычном исследовательском тексте само по себе не считается атакой.

5.1. Офлайн-корпус и реальные ответы

Новый офлайн-корпус содержит 12 целевых случаев. Для всех 12 получен ожидаемый исход; 4 из 4 обычных случаев дали пригодный предварительный ответ. Ни одно произвольное научное утверждение не было автоматически повышено до подтверждённого. Исходные восемь имитаций и первоначальные результаты диверсионного эксперимента остались без изменения.

В отдельной LIVE-проверке выполнены шесть вызовов qwen/qwen3.5-35b-a3b на реальных текстовых фрагментах. Первые три ответа отклонены из-за превышения допустимой длины объяснения. После уточнения инструкции следующие три прошли техническую проверку и получили статус usable_preliminary. Общая подтверждённая стоимость этих шести вызовов — 0,00172399 USD; более ранний исторический ответ стоимостью 0,00042185 USD учитывается отдельно.

Ручная содержательная оценка второй серии зафиксировала три разных случая: предварительное совпадение по теме океанического микропластика без подтверждения конкретного результата; отсутствие предметной связи между доверием в распределённых системах и загрязнением океана; недостаточность данных при скрытой аннотации. Это проверка осторожности формулировок, а не независимое доказательство истинности ответов Qwen.

Статус usable_preliminary подтверждает соответствие техническому контракту, но не гарантирует достоверность интерпретации. По шести генерациям нельзя оценивать устойчивую частоту ошибок модели или делать выводы обо всех научных темах.

6. Воспроизводимость и ограничения

Поставляемый архив содержит исходный код, тесты, скрипты для повторного прогона, полный исходный корпус из 100 трасс, сводные таблицы и отдельные материалы проверки модели. Набор версии lab4-v1.1 содержит 77 автоматических тестов, проверенных при подготовке исходного выпуска; изменение оформления данного отчёта не изменяет код или экспериментальные данные.

Изначальные результаты находятся в experiments/lab4/results/; новый проверочный корпус — в experiments/lab4_v1_1/; порядок воспроизведения описан в docs/lab4_v1_1_reproduction.md. В ZIP включены локальные зависимости для Windows 11 / Python 3.14, поэтому обязательные офлайн-проверки не требуют подключения к сети и API-ключа. Происхождение данных и контрольные SHA-256 зафиксированы в сопровождающих файлах.

Ограничения: синтетические материалы и заданные воздействия не покрывают всех стратегий реального противника; идентификатор отправителя не аутентифицирован криптографически; фиксированный порядок запусков и небольшое число повторов ограничивают статистические выводы о задержках. Проверка буквальной цитаты и её идентификатора не равна независимой семантической верификации содержания. Для эксплуатации с внешними пользователями требуются аутентификация источников сообщений, расширенное тестирование и независимая оценка научных выводов.

Заключение

В ходе диверсионного исследования выявлены пять воспроизводимых классов нарушений политики взаимодействия агентов. После введения адресных проверок количество нарушений на исследованном корпусе снизилось с 25 до 0, корректных исходов стало 50 из 50 вместо 25 из 50; при этом в части сценариев возросло время обработки из-за повторного назначения задач. Отдельная доработка доказательного контура исключила автоматическое признание произвольного пересказа научным фактом на основании одной подлинной цитаты. Три повторных реальных ответа Qwen пригодны для предварительной аналитики, но не заменяют независимую научную проверку. Полученные результаты подтверждают эффективность выбранных защит в рамках испытанного стенда.

Источники и материалы воспроизведения

[1] ResearchRadar MAS. Архив исходного проекта, тег lab3-v1.1; контрольный SHA-256 архива: da223cc3ff29e0a0842c159270c4697ca3d5960d0359e6388119de8f56caaa2a.

[2] ResearchRadar MAS. Исходный диверсионный эксперимент: experiments/lab4/results/metadata.json, raw.csv, summary.json, paired.json и трассы в traces/.

[3] ResearchRadar MAS. Дополнительная проверка доказательного контура: experiments/lab4_v1_1/cases.json, results/, live/, live_round2/ и live_manual_review.json.

[4] ResearchRadar MAS. Контракт доказательств и инструкция воспроизведения: docs/lab4_v1_1_evidence_contract.md и docs/lab4_v1_1_reproduction.md.

[5] OWASP. LLM01: Prompt Injection. https://genai.owasp.org/llmrisk/llm01-prompt-injection/ (электронный ресурс).

[6] Исходные коды и зафиксированные версии: https://github.com/KAndyD/ResearchRadar_MAS/releases/tag/lab4-v1.1 .